

FEDESARROLLO & BANCO INTERAMERICANO DE DESARROLLO

Agente de Revision de Literatura con IA

BID-IA · Adopcion de IA en Firmas — Colombia y LATAM

Arquitectura, metodologia de evaluacion
y resultados de la primera iteracion.

Mayo 2026 · Maria Alejandra Montoya

Contenido

1. **El problema** — ¿por que un agente?
2. **Arquitectura** — como esta construido
3. **El loop agentico** — como decide
4. **Fuentes de busqueda**
5. **Sistema de scoring v2**
6. **Resultados** — primera iteracion
7. **Proximos pasos**

Objetivo de esta revision: validar la arquitectura y criterios antes de correr los 6 pockets restantes. Se busca feedback sobre (1) pertinencia del scoring, (2) cobertura de fuentes, y (3) prioridades para revision manual.

1 · El problema

¿Por que necesitamos un agente para la revision de literatura?

La tarea sin agente

- ▶ 7 temas (pockets) $\times$ 60 papers = **420 papers**
- ▶ Leer abstract, calificar metodologia, verificar relevancia
- ▶ Decidir: Aceptado / Revisar / Rechazado
- ▶ Extraer sintesis estructurada de los aceptados
- ▶ Construir red de conexiones entre papers

$\approx$ 3–4 semanas por investigador

Lo que hace el agente

- ▶ Busca en **9 fuentes academicas** simultaneamente
- ▶ Aplica rubrica de 5 dimensiones de forma consistente
- ▶ Sintetiza findings, metodologia y relevancia para LATAM
- ▶ Guarda resultados localmente — segunda corrida cuesta $\approx$ \$0
- ▶ El investigador solo decide los casos **REVISAR**

Costo total: **\$5–7 USD** por corrida completa


Contexto: esta revision informa el diseno del **primer RCT de adopcion de IA en MiPyMEs de LATAM** (Guatiguara). La literatura debe responder preguntas concretas: que medir, como identificar efectos causales, que heterogeneidades anticipar.

2 · Arquitectura

¿Como esta construido el agente?

Arquitectura del sistema

Tres capas con responsabilidades claras



Capa 1 — Entrada

El investigador define el pocket y el modo (`search`, `review`, `full`). Desde ahí, el agente opera de forma autónoma.

Capa 2 — Inteligencia (dos modelos)

Sonnet ve el historial completo: planifica, decide que buscar, interpreta resultados y escribe el reporte de gaps.

Haiku recibe solo el paper a evaluar: aplica la rubrica y sintetiza. 10x mas barato por tarea puntual.

Capa 3 — Datos

Las tools Python son deterministas: llaman APIs, enriquecen con Crossref, deduplican y guardan. Sonnet nunca toca archivos directamente.

Arquitectura del sistema

Que ve y que hace cada componente

Sonnet 4.6 — Orquestador

Recibe en cada turno:

- ▶ Definición del pocket (queries, anchor papers, criterios)
- ▶ Estado actual del corpus (cuantos papers, scores, gaps)
- ▶ Resultado de la última tool ejecutada
- ▶ Historial de decisiones del loop (max 30 iter.)

Decide: que tool llamar, con que parametros, cuando parar.

Nunca: escribe archivos, llama APIs ni evalua papers directamente.

Haiku 4.5 — Evaluador y Sintetizador

Recibe por paper:

- ▶ Título, abstract, metadata enriquecida (DOI, citas, venue)
- ▶ Definición del pocket en el *system prompt*
- ▶ Rubrica de 5 dimensiones (D1–D5)

Devuelve: scores D1–D5, clasificacion (ACEPTA-DO/REVISAR/RECHAZADO), justificacion por dimension.

Costo: ≈\$0.0003 USD por paper.

Tools Python — Las 6 acciones disponibles

<code>search_papers</code>	Llama las 9 APIs con las queries del pocket
<code>enrich_metadata</code>	Crossref: agrega DOI, ISSN, citas formales, ORCID
<code>deduplicate</code>	Merge por DOI + similitud de titulo (>0.85)
<code>evaluate_coverage</code>	Score 0–1: papers aceptados vs. objetivo
<code>review_papers</code>	Llama Haiku por cada paper pendiente
<code>save_results</code>	Merge al JSON del pocket; genera reporte de gaps


Principio de diseno: Sonnet razona, las tools actuan. Cada decision de Sonnet queda en el historial y cada accion de una tool es reproducible de forma independiente.

3 · El loop agentico

¿Como decide el agente en cada iteracion?

El loop agéntico

Secuencia de una corrida -mode full



Paso 1 — Estado

Sonnet lee corpus actual y definicion del pocket (queries, anchor papers). Sabe que existe y que falta.

Pasos 2–4 — Busqueda

Busca en multiples fuentes, enriquece con Crossref, elimina duplicados. Score de cobertura decide si buscar mas.

Pasos 5–6 — IA (Haiku)

Haiku recibe la definicion del pocket en el *system prompt*. Solo sintetiza papers ACEPTADOS.

Paso 7 — Guardado

Merge inteligente: agrega papers nuevos sin pisar revisados. Reporte con gaps detectados.

4 · Fuentes de búsqueda

9 fuentes · 5 libres · 2 con key · 2 pendientes

9 fuentes de búsqueda academica

Fuente	Auth	Mejor para	Estado
Semantic Scholar	libre	CS, interdisciplinar, ArXiv+journals	activa
NBER	libre	WPs economia: Brynjolfsson, Autor, Acemoglu	activa
OpenAlex	libre	240M works, citation counts verificados	activa
ArXiv	libre	Preprints CS/AI 2024–2026	activa
World Bank	libre	WPs desarrollo, labor, LATAM	activa
CORE	Bearer	Texto completo open access	activa
SSRN	Elsevier	Preprints econ/finanzas	pendiente
PubMed	NCBI	Biomed (solo si pocket = salud)	auto-skip
IMF	propia	WPs macroeconomia	sin key

Crossref: enrich_metadata agrega journal, ISSN, citas formales y ORCID por DOI. Sin key, sin costo.

Resultados guardados 24h: segunda corrida del mismo pocket = 0 llamadas a APIs de búsqueda.

5 · Sistema de scoring v2

Inspirado en GRADE + EPPI-Centre Weight of Evidence · escala 0–14

Sistema de scoring v2

5 dimensiones independientes · escala 0–14

Dimension	Pts	Descripcion
D1 Identificacion causal	0–4	4=RCT preregistrado 3=DiD/IV/RD con tests 2=Panel FE 1=OLS 0=descriptivo
D2 Seniales de calidad	0–3	+1 venue top-5 econ o top CS +1 citas >100 o h-index >30 +1 replicado
D3 Validez externa LA-TAM	0–3	3=evidencia directa LATAM 2=MiPyMEs USA/Eur. 1=firmas grandes 0=no transferible
D4 Relevancia	0–3	Gate absoluto: D4=0 implica RECHAZADO sin importar D1–D3
D5 Recencia ajustada	–1/0/+1	+1=2023–26 GenAI 0=2020–22 o fundacional (>50 citas) –1=pre-2020 y <50 citas

ACEPTADO

score ≥ 9
o bien score ≥ 7 con D4=3 y D1 ≥ 2

REVISAR

score 5–8
revision manual

RECHAZADO

score < 5
o D4 = 0

Sistema de scoring v2

Frameworks de referencia: de donde viene cada dimension

GRADE

¿Lo usamos? Si, adaptado

Estandar en medicina y economia del desarrollo. Separa *calidad interna* del estudio de su *aplicabilidad* a politica.

Como lo adaptamos: la jerarquia RCT > DiD/IV > Panel > OLS > descriptivo viene directamente de GRADE. D1 es esencialmente su escala de evidencia causal.

Que no tomamos: GRADE tiene 8 criterios de downgrade (riesgo de sesgo, imprecision, etc.) que no implementamos por costo computacional.

EPPI-Centre WoE

¿Lo usamos? Si, como estructura

Weight of Evidence para revisiones sistematicas en ciencias sociales. Distingue *solidez del estudio* de *pertinencia de la pregunta*.

Como lo adaptamos: esa distincion es exactamente D1–D2 (solidez) vs. D4 (pertinencia). Un buen estudio en EEUU con D1=4 puede tener D4=1 si la pregunta no aplica al pocket.

Que no tomamos: WoE usa sintesis narrativa manual; nosotros la automatizamos con Haiku.

3ie Evidence Gap Maps

¿Lo usamos? Para los gaps

Metodologia del BID para mapear evidencia disponible vs. ausente. Matriz: disenio de identificacion × relevancia tematica. Celdas vacias = gaps.

Como lo adaptamos: el reporte de gaps que genera Sonnet sigue esta logica: cruza D1 (metodologia) × D3 (contexto LATAM) y reporta donde no hay papers.

Que no tomamos: 3ie requiere busquedas exhaustivas de literatura gris; nosotros limitamos a fuentes academicas top-tier.

En sintesis: no implementamos ninguno al pie de la letra. GRADE y EPPI informan la *estructura* de D1–D4; 3ie informa el *reporte de gaps*. Las tres son reconocidas por el BID, lo que facilita la validacion con contrapartes institucionales.

6 · Resultados

Primera iteracion — Pocket de Impacto Causal

Total procesados

72

Aceptados

26

36 % del total

Por revisar

40

56 % del total

Rechazados

6

8 % del total

Metricas clave

Coverage score	$0.66 > 0.6$
Score promedio aceptados	$\approx 10.2 / 14$
$D1 \geq 3$ en aceptados	88 %
$D4 = 3$ en aceptados	100 %
Corrida total	≈ 22 min
Costo API	$\approx \$0.12$ USD

Composicion de los 40 REVISAR

- ▶ Mayoría: $D1 \geq 2$ y $D4 = 3$ pero $D3$ bajo (EEUU/Europa)
- ▶ Son candidatos directos a aceptar tras revision manual
- ▶ Potencial: corpus puede subir a $\approx 55-60$ aceptados

Fuentes con mayor yield: NBER (Brynjolfsson, Humlum), Semantic Scholar (Dell'Acqua, Noy & Zhang), ArXiv preprints 2024-25

Gaps de cobertura detectados

- ▶ **LATAM / Sur Global:** <5 % del corpus tiene evidencia directa de LATAM. Mayoría son papers de EEUU/Europa.
- ▶ **MiPyMEs:** los RCTs disponibles son con trabajadores de grandes firmas (call centers, consultoras, tech). Evidencia en pequeñas firmas es escasa.
- ▶ **2024–2026:** cobertura mejora con ArXiv pero muchos papers de vanguardia son preprints sin revision formal.
- ▶ **Sectores:** concentracion en knowledge workers y CS. Manufactura y servicios basicos poco representados.

Implicaciones para el RCT Guatiguara

- ▶ El gap LATAM/MiPyME es la **razon de ser del experimento**: la literatura global no responde las preguntas locales.
- ▶ Heterogeneidad **novato vs. experto** bien documentada en EEUU — hipotesis directamente transferible al diseno.
- ▶ Outcomes mas replicables: productividad por hora y calidad de output. Son los mas medidos globalmente.
- ▶ Falta evidencia sobre **efectos de mediano plazo** (>6 meses): oportunidad de contribucion original del RCT.

7 · Proximos pasos

Agenda para la siguiente iteracion

Pipeline (automatico)

1. Correr `-mode search` en los 6 pockets restantes estimado \$3-4 USD
2. Correr `build_network.py` para grafo de citaciones
≈\$0.05 USD
3. Actualizar `main_dashboard.html` con corpus completo
4. Resolver SSRN API key con Elsevier

Revision manual (investigador)

1. Revisar los **40 papers en REVISAR** del Pocket de Impacto Causal via `review_interface.html`
2. Validar los 26 aceptados contra el juicio del equipo
3. Ajustar umbrales de scoring si hay discrepancias sistematicas
4. Agregar manualmente anchor papers no encontrados por las APIs

Meta DoD: >50 aceptados por pocket · Impacto Causal: 26 confirmados + 40 por revisar

Anexo

Ejemplo comparativo de frameworks de clasificacion

Anexo · Frameworks originales Estructura real de cada uno

GRADE

Grading of Recommendations Assessment

Tabla de certeza por outcome; columnas de evaluar downgrade/upgrade.

Outcome	Diseño	Sesgo	Cert.
Velocidad	RCT	Bajo	Alta
Calidad	RCT	Bajo	Alta
LATAM	—	—	Baja

EPPI-Centre WoE

Weight of Evidence · 4 componentes

Tres pesos independientes combinados en veredicto WoE D.

Comp.	Pregunta	Peso
WoE A	Calidad metodológica	Alto
WoE B	Relevancia diseño	Alto
WoE C	Relevancia foco	Medio
WoE D	Veredicto	Alto

3ie Evidence Gap Map

Matriz intervención × outcome

Cada celda = evidencia disponible. Celda vacía = gap.

	Productiv.	Empleo	Bienestar
IA · EEUU/Eur	Alto	Med	Bajo
IA · LATAM	Bajo	Gap	Gap
IA · MiPy-MEs	Gap	Gap	Gap

Que tomamos

GRADE

Jerarquia causal RCT > DiD > Panel > OLS (D1)

EPPI

Separación calidad del estudio (D1-D2) vs. pertinencia (D4)

3ie

Matriz gaps intervención × contexto → reporte de Sonnet

Que dejamos

8 criterios de downgrade por riesgo de sesgo interno

Síntesis narrativa manual por panel de expertos

Busqueda exhaustiva de literatura gris y no publicada

Gracias

El código, los datos y los dashboards interactivos están disponibles en el repositorio del proyecto.

```
$ python scripts/agent.py -pocket evaluacion_experimental -mode full
```

Pipeline completo: búsqueda · enriquecimiento · deduplicación · review · síntesis · guardado

Costo: ≈\$0.12 USD · Tiempo: ≈20 min

Maria Alejandra Montoya · m.montoyac@uniandes.edu.co

Fedesarrollo & BID · Mayo 2026